

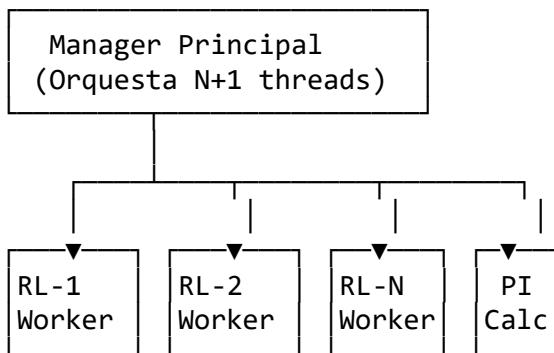
1. DISEÑO CONCISO: REGRESIÓN LINEAL CON CONCURRENCIA Y PI

Javier Felipe Rosero Sandoval

Resumen

Paralelizar regresión lineal en N threads + 1 thread calculando PI en paralelo usando Monte Carlo.

Arquitectura



Componentes Principales

1. DataPartitioner

- Divide dataset en N mini-batches iguales
- Valida cobertura completa
- Thread-safe con mutex

Métodos:

<code>create_partitions()</code>	→ divide en N partes
<code>get_partition(id)</code>	→ retorna partición i
<code>validate_partitions()</code>	→ verifica integridad

2. LinearRegressionWorker (xN threads)

- Procesa mini-batch asignado
- Calcula gradientes locales
- Sincroniza con barrera cada sync_frequency épocas

Métodos:

<code>compute_gradient()</code>	→ (dw, db, mse)
<code>update_weights(dw, db)</code>	→ actualiza parámetros

```
synchronize_with_others()      → promedia con otros workers  
run(epochs)                  → loop principal
```

Sincronización: - Cada worker calcula independientemente - Cada sync_frequency épocas: promedian pesos - Barrera sincroniza a todos antes de continuar - Ejemplo: epochs 0-49 independientes → epoch 50 sincronización

3. MonteCarloPiCalculator (1 thread)

- Genera puntos aleatorios en $[0,1]^2$
- Cuenta cuántos caen dentro círculo unitario
- $\text{PI} \approx 4 \times (\text{dentro} / \text{total})$

Métodos:

```
generate_random_points(n)    → genera n puntos  
count_inside_circle()       → cuenta puntos dentro  
estimate_pi()              → calcula  $\pi$  estimado  
run_concurrent()           → emite estimaciones cada 100ms
```

4. ConcurrentLinearRegressionManager

- Crea ThreadPoolExecutor con $N+1$ threads
- Lanza workers en paralelo
- Sincroniza con CyclicBarrier
- Promedia resultados finales

Métodos:

```
initialize(X, y, num_threads)  
train_async(epochs)          → retorna Future  
predict(x)                 → predicción thread-safe  
get_metrics()               → histórico convergencia
```

Flujo de Ejecución

T0: Inicialización

```
└─ Partitionar datos en 2 workers  
  └─ W1: [1,2,3] → y=[2,4,6]  
  └─ W2: [4,5] → y=[8,10]
```

T1-T50: Épocas 1-50 (sin sincronización)

```
└─ W1: Gradiente descent local  
└─ W2: Gradiente descent local  
└─ PI: Monte Carlo paralelo  
└─ DIVERGEN (distintos w, b locales)
```

T51: Sincronización @ epoch 50

```
└─ W1: w=1.2, b=0.15  
└─ W2: w=1.8, b=0.25
```

- └ Promedio: $w=1.5$, $b=0.2$
- └ AMBOS actualizan a promedios
- └ Barrera: esperan juntos

T52-T100: Épocas 51-100

- └ Ambos con $w=1.5$, $b=0.2$ iniciales
- └ Vuelven a divergir
- └ Convergen gradualmente

T101: Final

- └ $w_{final} \approx 2.0$
- └ $b_{final} \approx 0.0$
- └ PI ≈ 3.14159265

Ventajas

Ventaja	Descripción
Escalabilidad	$O(1)$ overhead con N threads
CPU 100%	$N+1$ threads siempre activos
Monitoreo vivo	PI se estima en tiempo real
Convergencia	Sincronización estabiliza aprendizaje
Thread-safe	Mutex + Barrier previenen races

Consideraciones

Overhead de sincronización: Cada barrera tiene costo ($\sim 1-2\text{ms}$)

Divergencia temporal: Workers divergen entre sincronizaciones (normal)

Comunicación: Usar memoria compartida, no paso de mensajes
